

Universidade Federal de Alagoas
Instituto de Computação

Processamento Digital de Imagens
Professor Tiago Vieira

Hiago Cavalcante e Luana Ferreira
Revisão Bibliográfica

Sumário

1	Introdução	3
2	Artigos relacionados publicados em revistas	3
2.1	COBRA: A combined regression strategy	3
2.2	Image Denoising by Sparse 3-D Transform-Domain Collaborative Filtering .	3
2.3	Image Denoising based on non local-means filter and its method Noise Thresholding	4
2.4	An Intelligent Approach to Image Denoising	5
3	Artigos relacionados publicados em conferências	6
3.1	Image Restoration in Non-Linear Filtering Domain using MDB approach . .	6
3.2	A non-local algorithm for image denoising	7
3.3	Collaborative Filtering with Stacked Denoising AutoEncoders and Sparse Inputs	8
3.4	Collaborative Filtering Denoising Algorithm Based on The Nonlocal Centralized Sparse Representation Model	9
3.5	A universal image quality index	10
3.6	A new class of nonlinear filters for image enhancement	10
3.7	Image denoising: Can plain Neural Networks compete with BM3D?	11
3.8	Beyond a Gaussian Denoiser: Residual Learning of Deep CNN for Image Denoising	12
3.9	Dual-domain image denoising	13
3.10	Universal Denoising Networks : A Novel CNN Architecture for Image Denoising	14

1 Introdução

Esse relatório contém uma revisão bibliográfica referente ao projeto da disciplina de Processamento Digital de Imagens, ministrada pelo professor Tiago Vieira. Esse projeto está em desenvolvimento e encontra-se em

<https://github.com/ferreiraluana/dip-project>.

O artigo escolhido como base desse projeto é intitulado *Non-linear aggregation of filters to improve image denoising* e está disponível em:

<https://paperswithcode.com/paper/non-linear-aggregation-of-filters-to-improve>.

2 Artigos relacionados publicados em revistas

2.1 COBRA: A combined regression strategy

O artigo [1] propõe um novo método para combinar vários estimadores de função de regressão. Ao invés de construir uma combinação otimizada linear ou convexa a partir de uma coleção básica de estimadores, os autores utilizaram essa ferramenta como um indicador coletivo da proximidade entre os dados de teste e treino. O resultado obtido foi uma performance assintoticamente menor que ou igual a L^2 como a menor combinação de estimadores básicos, ou seja, em termos de risco quadrático preditivo, o estimador se iguala ou supera a máquina primitiva. Além disso, o resultado é quase universal, pois atende todas as distribuições de (X, Y) tais que $E^2 < 1$. Sendo assim, o COBRA (*Combined Regression Alternative*) é um pacote da linguagem R. Como resultados, os autores concluíram que o algoritmo COBRA criou um alto padrão de referência em termos de velocidade e performance para problemas de predição no contexto de regressão.

2.2 Image Denoising by Sparse 3-D Transform-Domain Collaborative Filtering

O artigo [2] trata de uma nova estratégia de *denoising* em imagens inspirada em uma representação esparsa do domínio de transformada. Ao juntar blocos 2-D de frações de imagens em arrays de dados 3-D, é possível uma melhoria na esparsidade representada. Ao fazer uma transformação 3-D dessa junção de blocos, reduzir o espectro de transformação e realizar uma transformada inversa 3-D, obtém-se uma estimativa 3-D consistindo em blocos de imagem filtrados juntos. Ao atenuar o ruído, a filtragem efetuada revela muitos detalhes de cada conjunto de blocos, mantendo as características únicas de cada bloco. Como resultado, pode-se obter, a partir desse algoritmo que pode ser escalável, um desempenho no estado da arte de *denoising*, tanto na proporção sinal/ruído, quanto na qualidade visual.

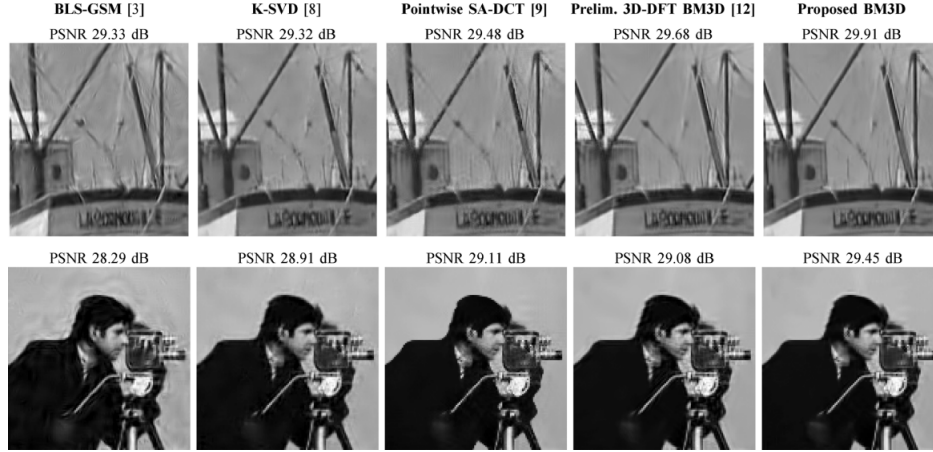


Figura 1: Aplicação de *denoising* utilizando métodos diferentes no artigo

2.3 Image Denoising based on non local-means filter and its method Noise Thresholding

O artigo [3] explicita como o filtro NL-means consegue realizar um denoising com eficiência, mas com uma certa quantidade grande de ruído, sua eficiência já não é a mesma, gerando muitos pedaços borrados na imagem. Seu objetivo é propor a mescla do filtro NL-means, com médias não locais e o método de limiar de ruído com *wavelet*, a fim de melhorar sua remoção de ruídos em imagens. Como resultado, teve um desempenho comparado com o filtro bilateral, NL-means e o filtro bilateral multi-resolução, considerando-se melhor que os citados pelas métricas do método *noise*, qualidade visual, PSNR e *Image Quality Index*. Uma limitação no seu desempenho pode ser rompida ao utilizar um filtro *NL-means* com kernel adaptativo e uma filtragem colaborativa usada em *BM3D*.




Figura 2: Aplicação de *denoising* utilizando filtros diferentes citados no artigo, como BF, NL-means, WT, MRBF, NLFMT e BM3D.

2.4 An Intelligent Approach to Image Denoising

Este artigo [4] apresenta uma abordagem inteligente recursiva baseada em rede neural celular (CNN) para eliminar o ruído de uma imagem mesmo na presença de uma proporção muito alta de ruído. A remoção de ruído de imagem é concebida como um problema de regressão entre o ruído e os sinais, o qual é resolvido usando CNN. Assim, os ruídos são detectados com informações ao redor e são removidos. O algoritmo proposto apresenta resultados promissores do ponto de vista quantitativo e qualitativo. Resultados experimentais do algoritmo de remoção de ruído inteligente proposto exibem alto desempenho em PSNR (Peak Signal-to-noise ratio) e efeito visual em imagens coloridas mesmo na presença de alta taxa de ruído. Como trabalho futuro, os autores pretendem estender esta pesquisa para remoção de ruído e restauração de imagem de estrutura de vídeo.



Figura 3: Resultados experimentais com diferentes variâncias de ruídos usando a abordagem proposta.

3 Artigos relacionados publicados em conferências

3.1 Image Restoration in Non-Linear Filtering Domain using MDB approach

O artigo [5] propõe uma técnica baseada em um detector não-linear de mínimos e máximos, ou *MDB Filter*, para a restauração de imagens. O contexto desse trabalho é justamente a necessidade de lidar com a degradação de imagens reconstruídas, prejudicando diretamente a sua qualidade em relação a imagem original. O objetivo é reconstruir uma imagem verdadeira a partir de uma imagem corrompida. Para isso, foi discutida a degradação de imagens, a qual ocorre com a adição de diferentes tipos de ruídos à imagem original e que esses ruídos podem ser modelados de diversas formas através de filtros, como o filtro mediano, por exemplo. Após comparar o modelo proposto com os filtros já existentes, os autores encontraram resultados muito superiores, os quais foram comprovados pelas métricas SNRI (*Signal to Noise Ratio Improvement*) e POSP (*Percentage of Spoiled Pixels*). As limitações desse trabalho consistem na retenção das propriedades das imagens restauradas e os autores sugerem estender o trabalho para detecção Fuzzy e ANN.

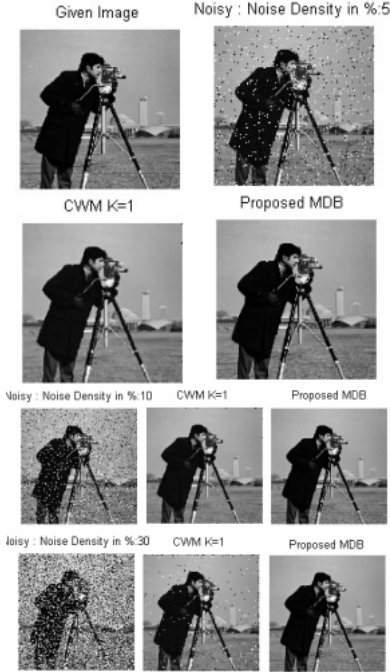


Figura 4: Principal contribuição de Satpathy et. al (2011)

3.2 A non-local algorithm for image denoising

Esse artigo [6] propõe um novo método denominado *noise*, a fim de comparar e avaliar o desempenho de formas de eliminação digital de ruído em imagens. Sua metodologia consiste em estimar e avaliar o método proposto para muitos algoritmos diversos de retirada de ruído, chamados de filtros de suavização local. Ainda, elabora um algoritmo chamado *NL-means*, baseando-se na média não local de todos os pixels da imagem, e o compara com os filtros citados anteriormente. Para avaliação dos resultados, foi utilizado o método *noise* descrito no trabalho, a qualidade visual da imagem restaurada e a métrica *MSE*, pela distância euclidiana entre a imagem restaurada e original.



Figura 5: Aplicação de *denoising* na imagem original da esquerda pra direita, utilizando filtragem Gaussiana, anisotrópica, variação total, de vizinhança e pelo NL-means proposto no artigo.

3.3 Collaborative Filtering with Stacked Denoising AutoEncoders and Sparse Inputs

O contexto desse trabalho [7] se dá em razão dos poucos artigos existentes sobre entradas esparsas, as quais são críticas para filtragem colaborativa. Os autores propõem uma arquitetura de rede neural que calcula uma fatoração de matriz não linear a partir de entradas de classificação esparsas, mostram experimentalmente um conjunto de dados que o método executa, bem como a melhor filtragem colaborativa algoritmos. Além disso, é fornecida uma implementação do algoritmo como uma ferramenta reutilizável plugin para Torch. As limitações dessa arquitetura são a lentidão durante o treinamento, sua natureza menos escalável e o fato de que o treinamento requer um alto número de hiperparâmetros para inicializar, aumentando a complexidade. Para inibir esses problemas, os autores sugerem que seja feito um trabalho futuro com a utilização de autoencoders.

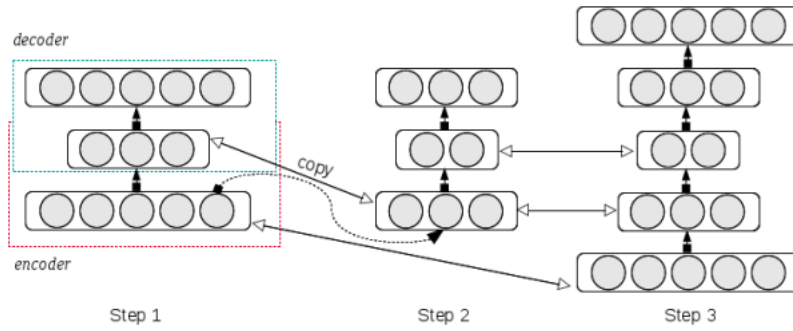


Figura 6: Principal contribuição de Strub et. al (2016)

3.4 Collaborative Filtering Denoising Algorithm Based on The Nonlocal Centralized Sparse Representation Model

Nesse artigo [8], é proposto um algoritmo baseado em correspondência de blocos e filtros 3D colaborativos para melhorar o processo de remoção de ruídos em imagens. Para isso, os autores empregam dois modelos de filtragem não-local diferentes em regiões de borda e regiões lisas. Adicionalmente, foi utilizada a representação esparsa não-local centralizada (NCSR) para capturar os coeficientes de esparsidade de *wavelet* e a similaridade não-local do bloco agrupado. Como resultado, os pesquisadores concluíram que o método proposto supera vários métodos de remoção de ruídos, o que é demonstrado a partir da métrica PSNR (Peak Signal-to-Noise Ratio), a qual mensura a relação sinal-ruído de pico. Como trabalho futuro, os autores sugerem mesclar o modelo NCSR com o princípio adaptativo de forma para melhorar ainda mais a performance da remoção de ruídos com esse algoritmo.




Figura 7: Principal contribuição de Liu et. al (2017) - performance do algoritmo BM3D na tarefa de remoção de ruído.

3.5 A universal image quality index

Nesse trabalho [9], é proposta um novo índice universal para a qualidade de imagem objetiva. Em vez de usar métodos tradicionais de soma de erros, o índice proposto é projetado a partir da modelagem de qualquer distorção da imagem como uma combinação de três fatores: perda de correlação, distorção de luminância e distorção de contraste. A limitação desse novo índice é que nenhum humano modelo de sistema visual é explicitamente empregado. Como resultado, os experimentos em vários tipos de distorção de imagem indicam que esse método tem uma performance significativamente melhor do que a métrica de distorção amplamente utilizada MSE (Mean Square Error), ou erro quadrático médio. Como trabalho futuro, os autores sugerem validar completamente o novo índice de qualidade com uma métrica que não seja sensível à energia de erros, capturando a perda real de informações.



Figura 8: Principal contribuição de Wang et. al (2002) - avaliação de imagens distorcidas pelo deslocamento médio, alongamento de contraste, desfoque e pela compressão JPEG.

3.6 A new class of nonlinear filters for image enhancement

Nesse artigo [10], dois novos tipos de filtros de Volterra não-lineares bidimensionais muito simples são introduzidos e aplicados ao aprimoramento do contraste da imagem. O primeiro tipo é baseado em uma generalização do o chamado algoritmo de Teager. Nesse contexto, uma análise teórica mostrou que esse tipo de filtro não linear funciona como um filtro passa-alta com peso médio local. Com base nesta análise, um segundo tipo de filtro não linear foi desenvolvido e funciona como um filtro passa-banda ponderado de média local. Por fim, a técnica de realce contraste de imagem é baseada na combinação da imagem original com sua versão filtrada obtida usando um dos dois filtros não lineares. Como resultado, os pesquisadores obtiveram índices que mostraram que a alta qualidade foi alcançada para imagens naturais com baixo custo computacional.




Figura 9: Principal contribuição de Mitra et. al (1991) - algoritmo de Teager modificado e a sua função de mapeamento.

3.7 Image denoising: Can plain Neural Networks compete with BM3D?

Nesse artigo [11], é citado como as técnicas de eliminação de ruído consistem em mapear uma imagem sem ruído a partir de uma ruidosa e como estes estão avançados. Assim, nesse trabalho é estimada uma abordagem de se obter esse mapeamento a partir de um MLP (*Multi layer perceptron*) em blocos de imagem. A partir dessa perspectiva, analisando a métrica PSNR e os métodos GSM, KSVD e BM3D, pode-se obter um resultado muito satisfatório comparado ao estado da arte de *denoising*. Ainda, é importante citar que redes neurais alcançam um desempenho excelente e, para tal, é necessária uma base de dados de treino grande o suficiente, assim como a capacidade da rede e o tamanho do *patch*, utilizando uma GPU. Como limitação do trabalho, conclui-se que, mesmo com o desempenho alcançado, ainda assim o MLP foi treinado para um único grau de ruído, tendo dificuldade de generalização.



Figura 10: Resultados do método de *denoising* do artigo comparado com BM3D.

3.8 Beyond a Gaussian Denoiser: Residual Learning of Deep CNN for Image Denoising

O artigo [12] propõe a construção de uma rede neural convolucional para remoção de ruídos de imagens, aprofundando-se no conceito de aprendizagem residual. Nesse trabalho, o diferencial vai além da adição de ruído gaussiano branco à imagem, pois a rede em questão consegue lidar com ruídos em níveis desconhecidos, tal qual a remoção de ruído gaussiano cego. Com essa estratégia, a DnCNN (Denoising Convolutional Neural Network) remove implicitamente a imagem limpa latente nas camadas ocultas. As aplicações dessa ferramenta são remoção de ruído gaussiano, super-resolução e desbloqueio de imagem JPEG. Por fim, resultados experimentais demonstraram que o método proposto não apenas produz um desempenho de remoção de ruído de imagem favorável quantitativa e qualitativamente, mas também tem tempo de execução promissor pela implementação da GPU. Em trabalhos futuros, os autores sugerem investigar modelos adequados de CNN para remoção de ruído de imagens com ruído complexo real e outras tarefas gerais de restauração de imagem.




Figura 11: Principal contribuição de Zhang et. al (2017) - arquitetura DnCNN proposta pelos autores.

3.9 Dual-domain image denoising

O artigo [13] explicita como métodos de eliminação de ruído são implementados nos domínios espacial e de transformada, cada um com seus detalhes e vantagens. Um deles é o BM3D (filtragem 3-D de *Block-Matching*), que utiliza ambos, mas com uma implementação não tão simples. Nesse trabalho, foi abordado uma nova forma híbrida de implementá-lo, até mesmo em qualidade. Como método, o trabalho utilizou uma abordagem híbrida, utilizando no domínio espacial o filtro bilateral, conhecido por preservar as propriedades das bordas da imagem, mesmo que não preserve texturas muito bem. Já no domínio de transformada, foi utilizado a transformada de Fourier de tempo curto (*STFT*) com encolhimento de *wavelet*. Como resultado, o método utilizado conseguiu remover ruídos de sinais 1-D e 2-D de forma eficaz e com bom desempenho.




Figura 12: Resultados obtidos no trabalho, avaliando o método *DDID* e *BM3D*. O *DDID* tem menos ruído em baixas frequências do que o *BM3D*.

3.10 Universal Denoising Networks : A Novel CNN Architecture for Image Denoising

O trabalho de [14] projeta uma nova arquitetura de rede para modelos de aprendizagem de imagem discriminativas, os quais são empregados para resolver o problema de redução de ruído de imagem em escala de cinza e em cores. Como resultado, foi possível observar que a arquitetura das redes propostas é consideravelmente mais superficial do que as atuais abordagens profundas baseadas em CNNs de última geração, pois os modelos resultantes levam a resultados muito competitivos para distorções AWGN enquanto eles também parecem ser muito robustos quando a degradação de ruído da entrada se desvia da suposição gaussiana. Ao contrário da maioria das abordagens de redes profundas existentes, as quais exigem a formação de um modelo específico para cada nível de ruído considerado, os modelos propostos são capaz de lidar com uma ampla gama de níveis de ruído usando um único conjunto de parâmetros aprendidos, enquanto eles são muito robustos quando a degradação da imagem latente não corresponde às estatísticas do ruído usado durante o treinamento. Como trabalhos futuros, o autor sugere investigar diferentes abordagens de correspondência de blocos para encontrar os trechos semelhantes usados na variante não local da rede proposta.

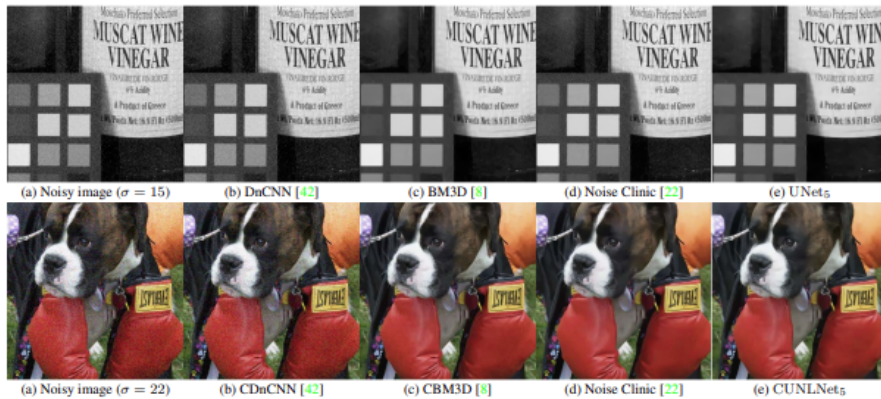


Figura 13: Contribuição de Lefkimmiatis (2018) - Resultados reais de remoção de ruído em tons de cinza e cores. O valor de σ é a estimativa do desvio padrão do ruído, fornecido como entrada adicional tanto para o BM3D quanto para as redes propostas.

Referências

- [1] Gérard Biau, Aurélie Fischer, Benjamin Guedj, and James D Malley. Cobra: A combined regression strategy. *Journal of Multivariate Analysis*, 146:18–28, 2016.
- [2] Kostadin Dabov, Alessandro Foi, Vladimir Katkovnik, and Karen Egiazarian. Image denoising by sparse 3-d transform-domain collaborative filtering. *IEEE Transactions on Image Processing*, 16(8):2080–2095, 2007.
- [3] Shreyamsha Kumar B. K. Image denoising based on non-local means filter and its method noise thresholding. *Signal, Image and Video Processing*, 7:1211–1227, 11 2013.
- [4] Tanzila Saba, Amjad Rehman, and Ghazali Sulong. An intelligent approach to image denoising. *Journal Of theoretical and Applied information technology*, 17(2):32–36, 2010.
- [5] SK Satpathy, S Panda, KK Nagwanshi, and C Ardil. Image restoration in non-linear filtering domain using mdb approach. *arXiv preprint arXiv:2204.09296*, 2022.
- [6] A. Buades, B. Coll, and J.-M. Morel. A non-local algorithm for image denoising. In *2005 IEEE Computer Society Conference on Computer Vision and Pattern Recognition (CVPR’05)*, volume 2, pages 60–65 vol. 2, 2005.
- [7] Florian Strub and Jeremie Mary. Collaborative filtering with stacked denoising auto-encoders and sparse inputs. In *NIPS workshop on machine learning for eCommerce*, 2015.
- [8] Jing Liu, Ruijiao Liu, Jinlei Chen, Yajie Yang, and Douli Ma. Collaborative filtering denoising algorithm based on the nonlocal centralized sparse representation model. In *2017 10th International Congress on Image and Signal Processing, BioMedical Engineering and Informatics (CISP-BMEI)*, pages 1–6. IEEE, 2017.
- [9] Zhou Wang and Alan C Bovik. A universal image quality index. *IEEE signal processing letters*, 9(3):81–84, 2002.
- [10] Sanjit K Mitra, Hui Li, I-S Lin, and T-H Yu. A new class of nonlinear filters for image enhancement. In *Acoustics, Speech, and Signal Processing, IEEE International Conference on*, pages 2525–2526. IEEE Computer Society, 1991.
- [11] Harold C Burger, Christian J Schuler, and Stefan Harmeling. Image denoising: Can plain neural networks compete with bm3d? In *2012 IEEE conference on computer vision and pattern recognition*, pages 2392–2399. IEEE, 2012.
- [12] Kai Zhang, Wangmeng Zuo, Yunjin Chen, Deyu Meng, and Lei Zhang. Beyond a gaussian denoiser: Residual learning of deep cnn for image denoising. *IEEE transactions on image processing*, 26(7):3142–3155, 2017.
- [13] Claude Knaus and Matthias Zwicker. Dual-domain image denoising. In *2013 IEEE International Conference on Image Processing*, pages 440–444. IEEE, 2013.

- [14] Stamatios Lefkimmiatis. Universal denoising networks: a novel cnn architecture for image denoising. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 3204–3213, 2018.